

KONTAKT

Konstanz
Kathie.Mayer@yahoo.de
kmayer24.github.io
github.com/KMayer24
0009-0000-5573-478X

KOMPETENZEN

PROGRAMMIERUNG

Python (pandas, NumPy, scikit-learn)
R (tidyverse, ggplot2)
SQL, Bash, Stata, MATLAB
C++ (Grundlagen)

NLP & GENERATIVE AI

LLM-Evaluation und Bias-Analyse
Prompt Engineering
Transformer Fine-Tuning
Textklassifikation
Word Embeddings (Word2Vec, FastText)
PyTorch, Hugging Face Transformers, Gensim

MACHINE LEARNING & STATISTIK

Klassifikation und Regression
Statistische Inferenz, Hypothesentests
Bootstrapping

DATA ENGINEERING & TOOLS

Relationale Datenbanken, ETL
Web Scraping, APIs
HPC-Cluster (Slurm)
Linux-Server
PostgreSQL, Parquet, Git/Git LFS
Conda, Unit Testing, Jupyter
VS Code, Quarto, LaTeX

KATHARINA MAYER

Data Scientist mit Schwerpunkt NLP und Large Language Models
Interdisziplinärer Hintergrund in Recht und Wirtschaft

BERUFSERFAHRUNG

Universität Konstanz
Prof. Dr. David Garcia
seit 05/2026

Research Assistant

- **Erkennung KI-generierter Rechtstexte:** Entwicklung einer Python-Pipeline (Prompt-Design, Qualitätsprüfungen, Unit-Tests), die mit Open-Source-LLMs synthetische Rechtstexte erzeugt; Aufbau eines Benchmark-Datensatzes zur Erkennung KI-generierter Texte; Ausführung per Slurm auf einem HPC-Cluster
- **Social-Media-Daten:** Web Scraping von 1,48 Mio. X/Twitter-Posts deutscher und britischer Partei- und Medienaccounts (2005–2022) mit twscrape; fortsetzbare Python-Pipeline auf einem Linux-Server mit monatlicher Vollständigkeitsprüfung

Deutscher Apotheker Verlag, Stuttgart
seit 04/2024

Werkstudentin Rechte und Lizenzen

- Digitalisierung und Archivierung von Lizenzverträgen
- Vertragsprüfung und Abgleich von Vertrags- und Systemdaten

Elternzeit
07/2021 – 03/2024

BRP Renaud und Partner mbB, Stuttgart
09/2020 – 10/2020

Pflichtpraktikum Gesellschaftsrecht und M&A

- Gutachten zu Fragen des Gesellschafts-, Zivil- und Internationalen Privatrechts, u. a. zu GmbH-Einziehungsklauseln und § 132 AktG
- Prüfung der Anwendbarkeit von Rom-I-VO und CISG auf einen deutsch-chinesischen Kaufvertrag; Entwurf von Vertragsdokumenten

IBM Deutschland GmbH, Ehningen
08/2016 – 04/2017

Werkstudentin und Praktikantin Hardware Sales

- Betreuung von Investment Reviews und Deal Registrations; Entscheidungsunterlagen für das Management

AUSBILDUNG

Universität Konstanz
10/2024 – heute

M.Sc. Social and Economic Data Science

Note	1,3 (vorläufig)
Vertiefung	Deep Learning, NLP und statistische Modellierung; Anwendung auf Rechts- und Social-Media-Daten
Masterarbeit	*Detecting Gender Bias in Judicial Language: A Projection-Based Analysis of Real and AI-Generated Opinions* (abgegeben 09/2026)

Universität Konstanz
seit 04/2019

Rechtswissenschaften, Bachelor of Laws (LL.B.)

Note	8,60 Punkte (vorläufig)
Schwerpunkt	Arbeits- und Sozialrecht
Bachelorarbeit	*Nutzung von Betriebsmitteln des Arbeitgebers zur Streikmobilisierung* (13 Punkte)

Universität Konstanz
09/2014 – 10/2018

B.Sc. Wirtschaftswissenschaften

Note	1,8
Schwerpunkt	Angewandte Ökonomie
Bachelorarbeit	*The Impact of Gender on Racial Discrimination in Grading* (Note 1,0)
Ausland	Charles University Prag (2017/18)

SPRACHEN

Deutsch	Muttersprache
Englisch	fließend
Spanisch, Französisch	Grundkenntnisse

INTERESSEN

Kochen • Sport • Reisen

PROJEKTE

Masterarbeit
2026

Gender Bias in Judicial Language

- **Daten:** Aufbau eines Korpus aus 1,14 Mio. US-Berufungsurteilen in PostgreSQL, inklusive Zuordnung der Richter*innen über extrahierte Namen
- **Embeddings:** Training von Word2Vec- und FastText-Modellen und Messung von Gender-Assoziationen über Zeit, Rechtsgebiete und Richtergeschlecht
- **LLMs:** Kontrafaktisches Experiment mit vier LLMs (4.032 Urteile zu echten Sachverhalten, nur das Geschlecht der Partei variiert) und Analyse von Bias in Entscheidung und Sprache

Data Science Project
2026 • Note 1,0

CourtListener Research Database

Manuskript eingereicht bei EPJ Data Science (11/2026)
Aufbau einer relationalen PostgreSQL-Datenbank zu US-Richter*innen, ihren Karrieren und Urteilen, inklusive Autorenzuordnung und Verknüpfung mit FJC-Fallmetadaten
Zenodo-DOI 10.5281/zenodo.23063945 • GitHub

Social Media Data Analysis
2025 • Note 1,0

The Impact of AI-Generated Comments on Sentiment in YouTube Discussions

Erhebung von 68.019 Kommentaren zu Klimavideos über die YouTube Data API; Erkennung KI-generierter Kommentare mit einem DeBERTa-Detektor und Sentimentanalyse mit einem selbst per Fine-Tuning trainierten RoBERTa-Modell; Auswertung per multinomialer logistischer Regression
GitHub

Gruppenprojekt
2025 • Note 1,3

Gentrification Detection from Street View Images

Entwicklung eines Gentrifizierungsindex für San Francisco aus Zensusdaten und Klassifikation von Google-Street-View-Bildern mit acht trainierten CNN-Varianten